

비유사 신체 부위의 가상현실 운동 기술 습득 검증을 위한 이중 방법론 프레임워크: 인간 수행 능력과 계산 모델링의 통합적 접근

제 1부: 비유사 신체화 및 학습의 기초 원리

이 파트에서는 인간 증강 및 체화된 AI의 광범위한 맥락 안에서 본 연구의 이론적, 개념적
토대를 구축한다.

제 1장: 익숙하지 않은 신체 제어의 신경인지적 과제

1.1. 신체 스키마의 가소성과 운동 학습

인간의 뇌는 자신의 신체에 대한 두 가지 핵심적인 내적 표상을 유지하는데, 이는 신체 스키마(*body schema*)와 신체 이미지(*body image*)로 구분된다.¹ 신체 스키마는 주로 무의식적 수준에서 작동하는 신체의 동적 감각운동 모델로서, 환경 내에서 움직임을 안내하고 조정하는 역할을 한다.¹ 반면, 신체 이미지는 신체에 대한 의식적이고 지각적인 표상, 즉 우리가 생각하고 느끼는 우리 몸의 모습이다.¹ 본 연구에서 사용자가 가상의 꼬리를 제어하는 법을 배우는 것은 단순한 운동 기술 습득을 넘어선다. 이는 뇌의 신체 스키마를 근본적으로 변경하여, 선천적으로 존재하지 않았던 비유사(*non-analogous*) 부속지를 자신의 신체 일부로 통합하는 과정이다.¹

이러한 신체 표상의 가소성은 도구 사용 연구에서 명확하게 관찰된다. 인간은 망치나 라켓과 같은 도구를 반복적으로 사용함으로써 해당 도구를 마치 자신의 신체 일부처럼 느끼고 제어하게 되는데, 이는 도구가 사용자의 신체 스키마에 통합되었음을 시사한다.¹ 가상의 꼬리 역시 이러한 '도구'의 확장된 형태로 볼 수 있으며, 사용자는 시각적 피드백에 의존하여 이 새로운 부속지를 자신의 신체 표상에 편입시키는 법을 학습해야 한다. 이 과정은 뇌가 기존의

신체 모델을 수정하고 새로운 신체 부위의 운동 역학을 내재화하는 신경인지적 적응을 요구한다.

1.2. 내적 모델 구축에서 감각 피드백의 역할

정교한 운동 제어는 실제 감각 피드백을 기다리기보다, 행동의 감각적 결과를 예측하는 내적 모델(internal models)에 크게 의존한다.¹ 이 내적 모델은 크게 두 가지로 나뉜다. 순행 모델(forward model)은 특정 운동 명령이 어떤 감각적 결과를 낳을지 예측하는 역할을 하며, 역행 모델(inverse model)은 원하는 결과를 얻기 위해 어떤 운동 명령을 내려야 하는지를 계산한다.¹

본 연구의 핵심적인 제약 조건은 사용자가 오직 시각적 피드백만을 사용한다는 점이다. 이는 촉각이나 고유수용성 감각과 같은 추가적인 감각 피드백을 제공하는 다른 연구들과 대조된다.¹ 이러한 조건에서 사용자는 단일한 감각 채널로부터 제공되는, 잠재적으로 지연될 수 있는 정보를 바탕으로 견고한 내적 모델을 구축해야 하는 어려운 과제에 직면한다. 사용자는 가상 꼬리의 움직임을 시각적으로 관찰하고, 자신의 제어 입력(예: 몸통 기울이기)과 그 결과 사이의 관계를 반복적으로 경험함으로써 꼬리의 운동 역학에 대한 순행 및 역행 모델을 점진적으로 형성해 나가야 한다. 이 과정의 효율성과 성공 여부는 학습 능력 검증의 핵심 지표가 된다.

1.3. 비유사 신체 제어에서 '학습'의 정의

본 연구에서 '학습'은 다차원적인 개념으로 정의된다. 이는 단순히 과제 수행 능력의 향상을 의미하는 것을 넘어, 사용자의 주관적 경험과 신체 표상의 객관적 변화를 포괄한다. 따라서 학습은 다음 세 가지 측면에서 종합적으로 평가되어야 한다.

첫째, 과제 수행 능력의 향상이다. 이는 완료 시간 단축, 성공률 증가, 궤적 오차 감소 등 정량적으로 측정 가능한 지표를 통해 평가된다.

둘째, 체화(embodiment) 감각의 변화이다. 체화는 외부의 대상(가상 꼬리)을 자신의 신체 일부로 느끼는 주관적인 경험을 의미하며, 주로 세 가지 하위 요소로 구성된다: 신체 소유감(Sense of Body Ownership, SoO), 행위 주체감(Sense of Agency, SoA), 그리고 자기 위치감(Sense of Self-Location, SoSL)이다.¹ 학습이 진행됨에 따라 이러한 체화 감각, 특히 자신이 꼬리를 의도대로 제어하고 있다는 느낌인 행위 주체감이 증가할 것으로 예상된다.

셋째, 신체 표상의 객관적인 변화이다. 이는 고유수용감각 드리프트(proprioceptive drift)와 같은 행동 기반 측정을 통해 평가될 수 있으며, 학습을 통해 뇌의 신체 스키마가 실제로 재구성되었는지를 보여주는 강력한 증거를 제공한다.¹ 이 세 가지 측면을 종합적으로

평가함으로써, 우리는 비유사 신체 부위 제어에 대한 피상적인 기술 습득을 넘어선 심층적인 신경인지적 적응 과정을 검증할 수 있다.

제 2장: 두 가지 검증 방법론 - 인간의 실측 데이터와 기계의 모사

2.1. 이중 방법론 접근의 논리적 근거

본 연구 계획의 핵심은 두 가지 상호보완적인 검증 방법론을 통합하는 데 있다. (A) 인간 중심 평가(Human-Centric Assessment)는 사용자의 주관적 경험과 실제 수행 능력에 대한 필수적인 '실측 데이터(ground truth)'를 제공한다. 이는 학습 과정에서 발생하는 미묘한 인지적, 감각적 변화를 포착하는데 있다. 반면, (B) 계산적 검증(Computational Validation)은 습득된 기술을 객관적이고 확장 가능한 분석 모델로 변환하여 제공한다.¹ 이 두 방법론을 결합함으로써, 한 방법의 약점을 다른 방법의 강점으로 보완하여 학습 효과에 대한 보다 강건하고 다각적인 결론을 도출할 수 있다.

인간 평가는 실제 경험의 본질을 담지만, 개인차가 크고 정량화하기 어려운 측면이 있다. 반대로, 계산 모델(RL 에이전트)은 객관적이고 재현 가능한 성능 지표를 제공하지만, 주관적인 경험의 질을 직접적으로 반영하지는 못한다. 따라서 이 둘을 통합하여 상호 검증하는 접근 방식은 연구의 타당성과 신뢰도를 극대화하는 최적의 전략이다.

2.2. 연구 패러다임으로서의 인간 참여형 AI

본 연구는 체화된 AI(Embodied AI)라는 새로운 연구 패러다임에 속한다. 체화된 AI 에이전트는 단순히 데이터를 처리하는 것을 넘어, 인간 사용자 및 환경과의 직접적인 상호작용을 통해 학습한다.¹ 본 계획에서 개발될 강화학습(RL) 에이전트는 단순한 분석 도구가 아니라, 인간의 시연으로부터 특정 과제에 대한 월드 모델(world model)을 학습하는 '체화된 AI 에이전트'이다.

이러한 접근 방식은 인간의 학습 과정을 계산적으로 모델링하고 분석할 수 있는 독특한 기회를 제공한다. 인간 학습자가 생성한 데이터를 기반으로 에이전트를 훈련시킴으로써, 우리는 인간의 운동 제어 전략, 학습 곡선, 그리고 기술의 본질을 정량적으로 포착할 수 있다. 이는 인간의 학습 능력 자체를 평가하는 새로운 창을 여는 것이다.

RL 에이전트는 인간 학습 능력에 대한 계산적 대리 지표(computational proxy)로서 기능할 수 있다. 'Embodied Tentacle' 연구는 제어 매핑 규칙의 설계가 "운동학적 적합성(Kinematics

Suitability for the User)"이나 "일상 행동과의 일치성(*Correspondence with Everyday Actions*)"과 같은 요인 때문에 사용자의 수행 능력과 주관적 경험에 결정적인 영향을 미친다는 것을 보여주었다.¹ 강화학습 에이전트를 행동 복제(*behavioral cloning*) 방식으로 훈련시킬 때², 에이전트는 인간의 상태-행동 정책을 모방하도록 학습한다. 만약 인간이 운동학적으로 어색하고 비직관적인 매핑 규칙 때문에 학습에 어려움을 겪는다면, 그들은 비효율적이고 일관성 없는 시연 데이터를 생성할 것이다. 이처럼 품질이 낮은 데이터로 훈련된 에이전트는 당연히 낮은 성능을 보일 것이다. 반대로, 직관적이고 배우기 쉬운 매핑 규칙은 인간이 깨끗하고 효율적인 시연 데이터를 생성하도록 유도하며, 이는 결과적으로 높은 성능의 에이전트로 이어진다. 이는

매핑 설계 → 인간의 학습 용이성 → 시연 데이터의 품질 → **RL** 에이전트의 성능이라는 명확한 인과 관계 사슬을 형성한다.

결론적으로, 훈련된 **RL** 에이전트의 최종 성능은 인간-인터페이스 매핑 규칙의 '학습 용이성'에 대한 객관적이고 정량적인 척도로 사용될 수 있다. 이는 각기 다른 인터페이스 설계를 평가하고 비교하는 강력한 도구를 제공하며, 모든 설계 반복마다 대규모 인간 대상 연구를 수행할 필요성을 줄여줄 잠재력을 가진다.

제 2부: 인간 중심 학습 평가 프로토콜 (방법 A)

이 파트에서는 제공된 연구 자료들에서 확립된 방법론을 적극적으로 활용하여, 전체 사용자 연구 프로토콜을 상세히 기술한다.

제 3장: 실험 설계 및 장비

3.1. 참가자 및 절차

실험 참가자 모집 기준(예: 오른손잡이, 정상 또는 교정 시력, 특정 과제에 대한 사전 경험 없음)과 피험자 내 설계(*within-subjects design*)를 명시한다. 실험 절차는 표준적인 사전 테스트(*Pre-Test*) → 훈련(*Training*) → 사후 테스트(*Post-Test*) 구조를 따른다. 각 참가자는 모든 실험 조건에 참여하여 개인 간의 변동성을 통제한다.

3.2. VR 환경 및 꼬리 운동학

VR 시스템(예: Unity Engine, 특정 HMD 모델)에 대한 상세한 설명을 제공한다.¹ 여기에는 환경, 아바타, 가상 꼬리의 시각적 디자인이 포함된다. 꼬리의 운동학적 모델, 예를 들어 관절의 수, 각 관절의 자유도(

DOF) 등은 명시적으로 정의된다. 예를 들어, 꼬리는 10개의 직렬 연결된 관절로 구성되며, 각 관절은 2개의 회전 자유도를 가진다고 정의할 수 있다.

3.3. 제어 매핑 규칙

고정된 매핑 규칙은 정밀하게 기술되어야 한다. 예를 들어, "꼬리의 주된 굽힘(좌/우)은 사용자의 몸통 기울임(HMD 및 허리 트래커로 측정)에 매핑되고, 부차적인 굽힘(상/하)은 사용자의 머리 상하 움직임(pitch)에 매핑된다"와 같이 기술한다. 이 매핑 규칙은 본 연구의 핵심적인 독립 변수로서, 그 학습 가능성을 검증하는 대상이 된다.

3.4. 종합적 기술 평가를 위한 과제 설계

운동 제어의 다양한 측면을 평가하기 위해 기존 연구의 과제들을 변형하여 사용한다.

- **과제 1:** 정적 목표물 도달 과제: 공 만지기 과제에서 영감을 받아¹, 사용자는 3차원 공간의 무작위 위치에 나타나는 일련의 정지된 목표물을 꼬리 끝으로 정확하게 터치해야 한다. 이 과제는 제어의 정밀도와 위치 제어 능력을 측정한다.
- **과제 2:** 동적 경로 추적 과제: 'Embodied Tentacle' 연구의 장애물 통과 과제에서 영감을 받아¹, 이 과제는 사용자가 꼬리 끝으로 복잡하게 움직이는 3차원 경로를 추적하도록 요구한다. 이 과제는 예측 제어, 움직임의 부드러움, 그리고 협응 능력을 측정한다.

제 4장: 인간 수행 능력의 측정 및 지표

4.1. 객관적 수행 능력 지표

- 완료 시간: 시행 시작부터 목표물 도달 또는 경로 추적 성공까지 걸린 시간.
- 성공률: 성공적으로 완료된 시행의 비율.
- 궤적 오차: 과제 2에서, 사용자의 꼬리 끝 궤적과 목표 경로 사이의 평균 유clidean 거리 또는 동적 시간 왜곡(Dynamic Time Warping, DTW) 거리. 이는 연속 제어의 정확성을 직접적으로 측정하는 지표이다.

4.2. 사용자 움직임의 운동학적 분석

사용자의 물리적 신체(몸통/머리)에서 수집된 모션 데이터를 분석한다. 지표에는 움직임의 부드러움(예: 스펙트럼 호 길이 또는 저크 분석)과 움직임 효율성(제어 입력의 경로 길이)이 포함된다. 사전 테스트에서 사후 테스트로 갈수록 부드러움과 효율성이 증가하는 것은 운동 기술 습득의 전형적인 특징이다.

4.3. 주관적 및 신체 스키마 지표

- 체화 설문지: 훈련 전후에 실시되는 7점 리커트 척도 설문지로, 검증된 도구에서 문항을 차용하여 ¹신체 소유감(SoO), 행위 주체감(SoA), 그리고 '초과 수족 감각(supernumerary limb sensation)'(Q3 in ¹)을 평가한다. 또한 'Kinematic Altering Illusion' 연구에서 영감을 받아 ¹, 신체 이미지의 변화를 탐색하기 위해 인지된 '부드러움'이나 운동학적 특성에 대한 질문을 포함한다.
- 고유수용감각 드리프트 과제: 신체 스키마의 변화를 객관적으로 측정하기 위해, 시야를 가린 상태에서 사용자가 제어에 사용된 자신의 신체 부위(예: 몸통)의 인지된 위치를 가리키는 과제를 훈련 전후에 실시한다. 훈련 후 인지된 위치에 체계적인 변화가 나타난다면, 이는 신체 스키마 재구성의 강력한 증거가 된다.¹

표 1: 인간 평가 지표 요약

지표 범주	특정 지표	설명	근거 및 출처
수행 능력	완료 시간 (s)	한 시행을 완료하는	속도와 효율성

		데 걸린 시간.	측정. ¹
	성공률 (%)	성공적으로 완료된 시행의 비율.	전반적인 과제 숙련도 측정. ¹
	궤적 오차 (DTW)	과제 2에서 최적 경로로부터의 편차.	연속 제어의 정확성 측정.
운동학	제어 입력 부드러움 (저크)	사용자의 물리적 제어 움직임의 가속도 변화율.	저크가 낮을수록 더 부드럽고 숙련된 제어를 의미.
주관적 평가	체화 점수 (SoO, SoA)	소유감과 행위 주체감에 대한 리커트 척도 점수.	체화의 주관적 경험 측정. ¹
	초과 수족 감각	추가적인 신체 부위를 가졌다는 느낌에 대한 리커트 척도 점수.	체화의 '추가' 측면 탐색. ¹
신체 스키마	고유수용감각 드리프트 (cm)	제어 신체 부위의 인지된 위치 변화.	신체 스키마 가소성의 객관적 측정. ¹

제 3부: 모방 학습을 통한 계산적 검증 프로토콜 (방법 B)

이 파트에서는 강화학습 에이전트를 생성, 훈련 및 평가하기 위한 기술적 사양을 설명한다.

제 5장: 모사 에이전트의 아키텍처

5.1. 프레임워크 및 도구

시뮬레이션 환경에서 지능형 에이전트를 훈련시키기 위한 강력한 오픈소스 프로젝트인 Unity ML-Agents Toolkit을 사용한다.⁴ 훈련은 Python 기반 트레이너를 사용하여 수행되며, 행동 복제(Behavioral Cloning) 사전 훈련 단계를 포함하는 근접 정책 최적화(Proximal Policy Optimization, PPO) 알고리즘을 활용할 가능성이 높다.⁴

5.2. 에이전트의 지각 정의 (관찰 공간)

에이전트의 입력 벡터는 의사 결정에 필요한 모든 정보를 포함해야 하며, 인간이 시각적으로 인지하는 것을 반영해야 한다. 관찰 공간(Observation Space)은 연속적이며 정규화된 값으로 구성된다.⁷

- 꼬리 상태: 모든 꼬리 분절의 관절 각도 및 각속도.
- 과제 상태: 목표물의 3차원 좌표(과제 1) 또는 목표 경로상의 다음 N개 지점(과제 2).
- 루트 상태: 목표물에 대한 꼬리 기반의 상대적 위치 및 방향.

5.3. 에이전트의 제어 정의 (행동 공간)

에이전트의 출력은 인간의 제어 입력 차원과 일치해야 한다. 행동 공간(Action Space)은 연속적인 값으로 구성된다.⁹

- 행동 벡터: 목표 몸통 기울기 각도와 머리 상하 각도를 나타내는 2차원 벡터로, 인간의 제어 신호를 직접적으로 모방한다.

표 2: RL 에이전트 관찰 및 행동 공간 명세

공간	변수	유형	크기	정규화	근거
관찰	꼬리 관절 각도	연속	N (관절 수)	[-1,1]	에이전트는 자신의 현재 구성을 알아야 함.

	꼬리 관절 속도	연속	N (관절 수)	[-1,1]	동적 상태 정보를 제공.
	목표물 위치 (상대적)	연속	3	[-1,1]	목표 지향적 행동의 핵심 정보.
	경로 지점 (상대적)	연속	3×M (경로 예측 수)	[-1,1]	과제 2에서 예측 제어를 위한 미래 막스 제공.
행동	목표 몸통 기울기	연속	1	[-1,1]	주된 인간 제어 입력을 모방.
	목표 머리 상하 움직임	연속	1	[-1,1]	부차적인 인간 제어 입력을 모방.

제 6장: 에이전트 훈련 및 평가 프로토콜

6.1. 시연 데이터 로깅

각 인간 참가자의 훈련 단계 동안, 시간 동기화된 상태-행동 쌍을 높은 주파수(예: 90Hz)로 기록한다. '상태'는 시간 t 에서의 에이전트 관찰 벡터이고, '행동'은 시간 t 에서의 인간 제어 입력 벡터이다. 이를 통해 각 참가자에 대한 고유한 시연 데이터셋이 생성된다.³

6.2. 행동 복제를 통한 훈련

각 참가자의 데이터셋에 대해 별도의 신경망 정책을 훈련시킨다. 행동 복제(Behavioral Cloning, BC)는 모방 학습을 지도 학습 문제로 취급한다. 즉, 신경망은 주어진 상태(St)에서 인간의 행동(At)을 예측하도록 학습한다. 이는 사용자가 학습한 제어 전략을 직접적으로 복제하는 방식이다.¹¹

6.3. 에이전트 벤치마킹

훈련된 각 에이전트는 과제 1과 과제 2에 대해 표준화된 100회의 시행으로 구성된 테스트 세트에서 평가된다. 에이전트의 성능은 인간과 동일한 객관적 지표(완료 시간, 성공률, 궤적 오차)를 사용하여 측정된다. 이를 통해 인간과 에이전트 간의 직접적이고 일대일 비교가 가능하다.

제 4부: 통합 분석 및 종합

이 파트는 두 방법론이 통합되어 고차원적인 통찰을 생성하는 연구의 분석적 핵심이다.

제 7장: 인간 학습과 에이전트 성능의 상관관계 분석

7.1. 인간 학습 이득 정량화

각 참가자에 대해, 각 수행 능력 지표에 대한 '학습 이득(Learning Gain)' 점수를 계산한다 (예: (Timepre-Timepost)/Timepre). 또한 주관적 점수의 변화량(예: Embodimentpost-Embodimentpre)도 계산한다.

7.2. 통계적 상관관계 분석

주요 가설을 검증하기 위해 일련의 피어슨 상관관계 분석을 수행한다.

- 가설 1: 참가자의 수행 능력 학습 이득은 해당 참가자의 데이터로 훈련된 에이전트의 최종 성공률과 양의 상관관계를 가질 것이다.
- 가설 2: 참가자의 훈련 후 최종 체화 점수(특히 행위 주체감)는 해당 에이전트의 성능과 양의 상관관계를 가질 것이다.

이러한 상관관계 분석은 두 방법론을 연결하는 핵심적인 다리 역할을 한다. 행위 주체감(SoA)은 자신이 제어하고 있다는 느낌을 의미한다.¹ 높은 SoA를 느끼는 사용자는 자신의 행동이 목적에 부합하고 효과적이라고 느끼므로, 깨끗하고 결단력 있는 제어 신호를 생성할 가능성이 높다. 반면, 낮은 SoA를 느끼는 사용자는 서투름을 느끼며, 번덕스럽고 주저하는 제어 신호를 생성할 수 있다. 행동 복제는 이러한 신호의 질적 차이를 그대로 포착한다. 높은 SoA를 보인 사용자의 데이터로 훈련된 에이전트는 명확하고 효과적인 정책을 상속받는 반면, 낮은 SoA 사용자의 데이터로 훈련된 에이전트는 노이즈가 많고 비효율적인 정책을 상속받게 된다.

이러한 논리적 연결은 주관적이고 내적인 감정(행위 주체감)과 객관적이고 외적인 측정치(RL 에이전트 성능) 사이에 검증 가능한 연결고리를 설정한다. 만약 강한 상관관계가 발견된다면, 이는 에이전트의 성능이 사용자의 주관적인 제어감에 대한 행동적 지표(behavioral marker)로 기능할 수 있음을 시사한다. 이는 상호작용 시스템에서 사용자 경험을 측정하고 검증하는 강력하고 새로운 방법을 제공할 수 있다.

표 3: 핵심 상관관계 분석

인간 지표 (독립 변수)	에이전트 지표 (종속 변수)	가설 관계	근거
학습 이득 (완료 시간)	에이전트 최종 성공률	양의 상관관계	인간의 빠른 학습은 더 나은 시연 데이터를 생성해야 함.
훈련 후 SoA 점수	에이전트 최종 성공률	양의 상관관계	높은 제어감은 더 일관되고 학습 가능한 정책으로 이어져야 함.
훈련 후 궤적 오차	에이전트 최종 궤적	양의 상관관계	더 정확한 인간은 더

	오차		정확한 에이전트를 가르칠 것임.
고유수용감각 드리프트 변화량	에이전트 일반화 성능	탐색적	더 강한 신체 스키마 변화가 더 강건하고 일반화 가능한 정책으로 이어지는가?

제 8장: 인간 기술의 분석 모델로서의 에이전트

8.1. 검증을 넘어: 학습된 정책 분석

이 섹션에서는 훈련된 에이전트가 단순한 성능 점수를 넘어, 인간이 습득한 기술에 대한 심층 분석 도구로 어떻게 활용될 수 있는지 논의한다. 우리는 인간에게는 불가능한 "디지털 실험"을 에이전트에 수행할 수 있다.

8.2. 일반화 및 강건성 탐색

인간이 경험하지 않은 새로운 조건(예: 다른 목표 위치, 더 빠른 경로 속도)에서 과제를 수행하는 에이전트의 능력을 테스트한다. 이는 학습된 기술의 일반화 능력을 평가하는 것이다. 에이전트가 새로운 상황에 얼마나 잘 대처하는지를 통해, 인간 학습자가 습득한 기술이 특정 훈련 조건에 과적합되었는지, 아니면 일반적인 제어 원리를 내재화했는지를 판단할 수 있다.

8.3. 실패 모드 식별

에이전트가 실패하는 특정 상황을 분석함으로써, 인간이 학습한 능력의 경계를 추론할 수 있다. 예를 들어, 만약 모든 에이전트가 과제 2의 급격하고 빠른 회전 구간에서 실패한다면, 이는 해당 기동이 이 매핑 규칙 하에서 인간 학습자들에게 보편적인 도전 과제였음을 객관적으로

보여주는 증거가 된다. 이러한 분석은 인터페이스의 근본적인 한계나 인간 운동 제어의 제약을 밝혀내는 데 기여할 수 있다.

제 5부: 미래 체화 인터페이스를 위한 시사점 및 제언

이 마지막 파트에서는 연구 결과를 종합하고, 해당 분야에 미칠 영향을 전망한다.

제 9장: 체화 인터페이스 설계 및 검증을 위한 청사진

9.1. 설계 도구로서의 이중 방법론

결론적으로, 본 연구 계획은 단일 연구를 넘어 재사용 가능하고 강력한 프레임워크로 자리매김할 수 있다. 이 접근법은 다양한 제어 매핑, 감각 피드백 양식(예: ¹에서처럼 촉각 피드백 추가), 그리고 가상 신체 부위를 신속하게 프로토타이핑하고 정량적으로 비교하는데 사용될 수 있다. 개발 초기 단계에서 이 프레임워크를 적용하면, 사용자에게 더 직관적이고 배우기 쉬운 인터페이스를 체계적으로 설계하고 선택하는 데 도움이 될 것이다.

9.2. 향후 연구 방향

향후 연구 방향은 다음과 같다.

- 비교 연구: 이 프레임워크를 사용하여 'Embodied Tentacle' 연구에서 제시된 설계 요인들을 ¹정량적으로 검증하기 위해 여러 다른 매핑 규칙들을 비교한다.
- 장기 학습 연구: 훈련 기간을 연장하여 기술의 공고화 과정과 신체 스키마 변화의 장기적 안정성을 조사한다.
- 모방에서 증강으로: 행동 복제를 넘어 인간 피드백 기반 강화학습(RLHF)과 같은 더 진보된 AI 기술을 탐구한다. 이를 통해 에이전트가 단순히 인간 사용자를 모방하는 것을 넘어, 사용자를 능가하도록 학습하여 진정한 인간-AI 기술 시너지를 창출하는 방향으로 나아갈 수 있다.

참고 자료

1. 가상현실에서 추가 로봇 팔의 신체화.pdf
2. Training our ML agents - Arm Learning Paths, 9월 29, 2025에 액세스,
https://learn.arm.com/learning-paths/mobile-graphics-and-gaming/using_unity_machine_learning_agents/08-training-our-ml-agents/
3. Unity ML-Agents - Demonstration Recorder for Imitation Learning - YouTube, 9월 29, 2025에 액세스, <https://www.youtube.com/watch?v=Dhr4tHY3joE>
4. ML-Agents Toolkit Overview - GitHub Pages, 9월 29, 2025에 액세스,
<https://unity-technologies.github.io/ml-agents/ML-Agents-Overview/>
5. ML Agents | 2.3.0-exp.3 - Unity - Manual, 9월 29, 2025에 액세스,
<https://docs.unity3d.com/Packages/com.unity.ml-agents@2.3/manual/index.html>
6. Mastering Unity Machine Learning Agents: A Comprehensive Guide To Training, Integration, And Application In Game Development - Brain Pod AI, 9월 29, 2025에 액세스,
<https://brainpod.ai/mastering-unity-machine-learning-agents-a-comprehensive-guide-to-training-integration-and-application-in-game-development/>
7. Class Agent | ML Agents | 1.0.8 - Unity - Manual, 9월 29, 2025에 액세스,
<https://docs.unity3d.com/Packages/com.unity.ml-agents@1.0/api/Unity.MLAagents.Agent.html>
8. Agents - Unity ML-Agents Toolkit, 9월 29, 2025에 액세스,
<https://unity-technologies.github.io/ml-agents/Learning-Environment-Design-Agents/>
9. Example Learning Environments - Unity ML-Agents Toolkit - GitHub Pages, 9월 29, 2025에 액세스,
<https://unity-technologies.github.io/ml-agents/Learning-Environment-Examples/>
10. Struct ActionSpec | ML Agents | 2.0.0 - Unity - Manual, 9월 29, 2025에 액세스,
<https://docs.unity3d.com/Packages/com.unity.ml-agents@2.0/api/Unity.MLAagents.ActionSpec.html>
11. MimicPlay | Long-Horizon Imitation Learning by Watching Human Play, 9월 29, 2025에 액세스, <https://mimic-play.github.io/>
12. Deep Imitation Learning for Complex Manipulation Tasks from Virtual Reality Teleoperation - UC Berkeley EECS, 9월 29, 2025에 액세스,
<https://www2.eecs.berkeley.edu/Pubs/TechRpts/2020/EECS-2020-190.pdf>